



第七周 分类问题进阶



本周实验内容



- 对20newsgroups数据集进行分类后,计算精确率(precision), 召回率(recall)和F分数(F-score)
- 根据分类结果画出混淆矩阵 (confusion matrix)
- 本次实验无作业





总体准确度 (overall accuracy)

✓ 该性能度量指标 (evaluation metric) 针对的是整个数据集中的所有样本





・ 考虑如下情况:

- ✓ 共100个西瓜, 其中90个是熟瓜, 10个是生瓜;
- ✓ 某个分类器将8个生瓜错误地分类成了熟瓜;
- ✓ 此时overall accuracy = 0.92
- 假设:找到生瓜比找到熟瓜更重要;
- 该分类器只找到2个生瓜(共10个),因此性能应该算差;
- 所以需要定义一种新的性能评估指标来描述上述情况。





- 召回率 (recall): "找到了某个类别的多少样本"
 - ✓ 生瓜的 recall = 被正确分类为生瓜的样本数 真实类别为生瓜的样本数
 - ✓ 生瓜的 $recall = \frac{2}{10} = 0.2$
 - ✓ 因为召回率为0.2, 所以分类器未能有效地找到生瓜
 - ✓ 熟瓜的 recall = 被正确分类为熟瓜的样本数 真实类别为熟瓜的样本数
 - ✓ 熟瓜的 $recall = \frac{90}{90} = 100\%$





- 精确率 (precision): "找对了某个类别的多少样本"
 - ✓ 生瓜的 precision = 被正确分类为生瓜的样本数 被分类为生瓜的样本数
 - ✓ 生瓜的 $precision = \frac{2}{2} = 1$
 - ✓ 因为精确率为1, 所以被分类器识别为生瓜的瓜大概率确实是生瓜

- \checkmark 熟瓜的 precision = $\frac{被正确分类为熟瓜的样本数}{被分类为熟瓜的样本数}$
- ✓ 熟瓜的 $precision = \frac{90}{98} = 91.83\%$





• F分数 (F-score): 召回率和精确率的调和平均数

$$Fscore = 2 \times \frac{precision \times recall}{precision + recall}$$





四种分类情况:

- ✓ True positive (TP): 真实类别为y, 被分类为y
- ✓ False positive (FP): 真实类别为~y, 被分类为y
- ✓ True negative (TN): 真实类别为~y, 被分类为~y
- ✓ False negative (FN): 真实类别为y, 被分类为~y

•
$$recall = \frac{TP}{TP + FN}$$

•
$$precision = \frac{TP}{TP + FP}$$





• 导入需要使用的方法:

导入计算召回率,精确率和F分数的方法 from sklearn.metrics import accuracy_score, recall_score, precision_score, f1_score





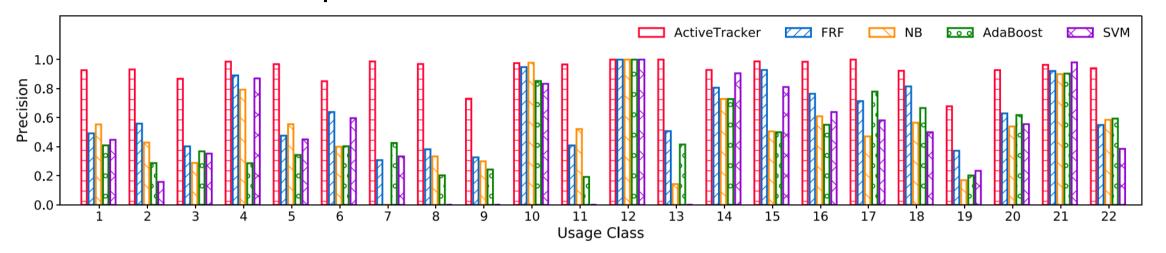
• 计算上节课分类结果的召回率,精确率和F分数:

```
acc = accuracy score(y test, y predict)
recall = recall score(y test, y predict, average=None)
precision = precision score(y test, y predict, average=None)
f1 = f1 score(y test, y predict, average=None)
print('Overall accuracy: ', acc)
print('Recall: ', recall)
print('Precision: ', precision)
print('F1-score: ', f1)
```

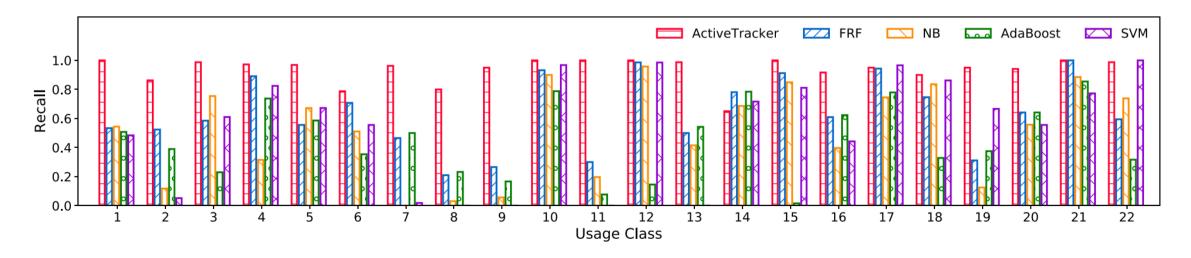




• 回顾: 使用Matplotlib绘制柱状图



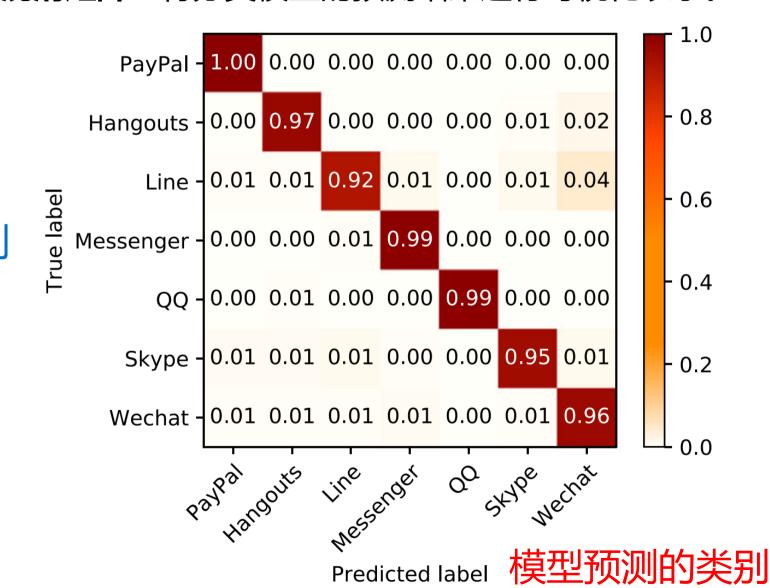
(a) Precision







· 混淆矩阵: 将分类模型的预测结果进行可视化表示。

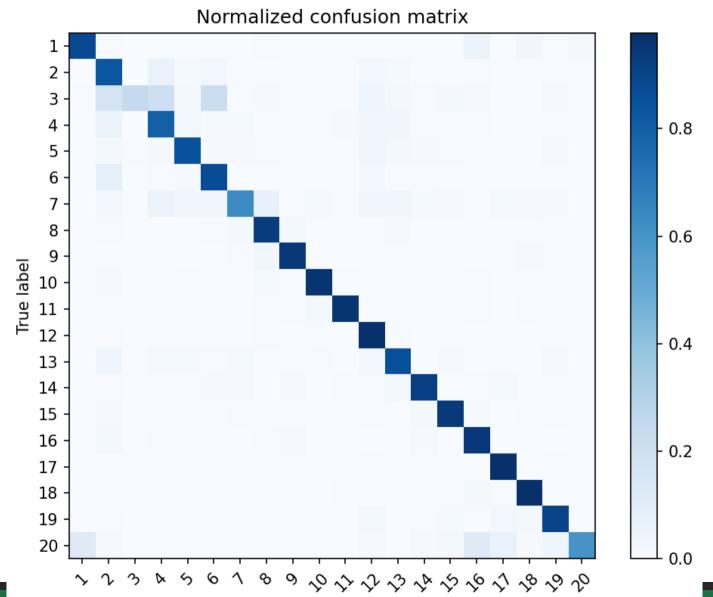


12





· 绘制混淆矩阵:资料/实验课ppt/naïve_bayes.py



Predicted label

结束语



谢谢!